국가데이터처

인구추계팀 인턴 업무 (2026.03~2026.08)

: AI 방법론 활용

2026.07.31

사회통계국 인구추계팀
청년 인턴 : 최승연

목차

I 월별 업무 소개

II 조사 및 정리

III 출산 (LSTM, Transformer)

IV 사망 (LSTM, Transformer)

V 국제이동 (LSTM, Transformer)

VI 시사점 및 느낀점

Ⅰ. 월별 업무 소개

3월

- AI 방법론 학습
- 분석 코드 정리

4월

- 국제이동 자료조사
(2025년 외국인 유출입 정책)
- 분석 코드 정리 및 고도화
- 청년 인턴 프로젝트

5~6월

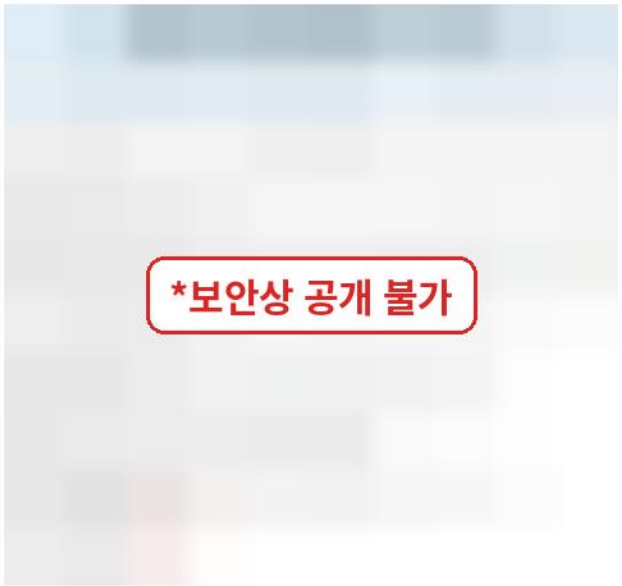
- 출산 및 사망 분석
- 공변량 기반 모델 재정립
- 청년 인턴 프로젝트

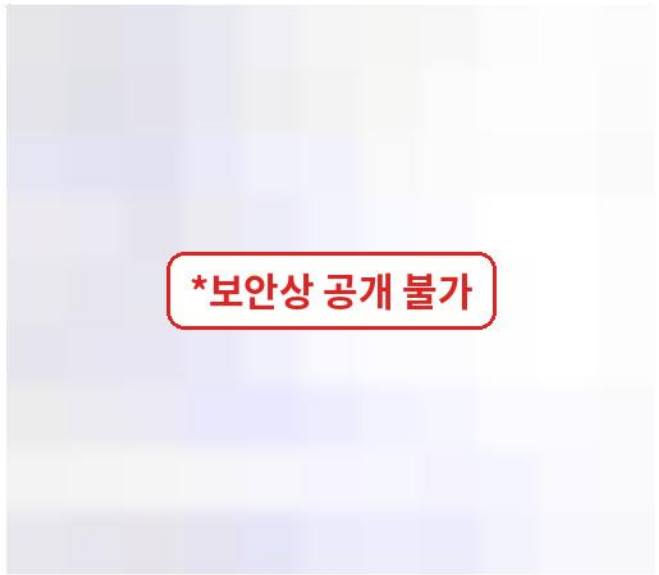
7월

- 국제이동 보도자료 검토 및 분석
- 최종 성과 정리 및 산출

II. 조사 및 정리

AI 활용 인구추계 방법론 연구 코딩 분석



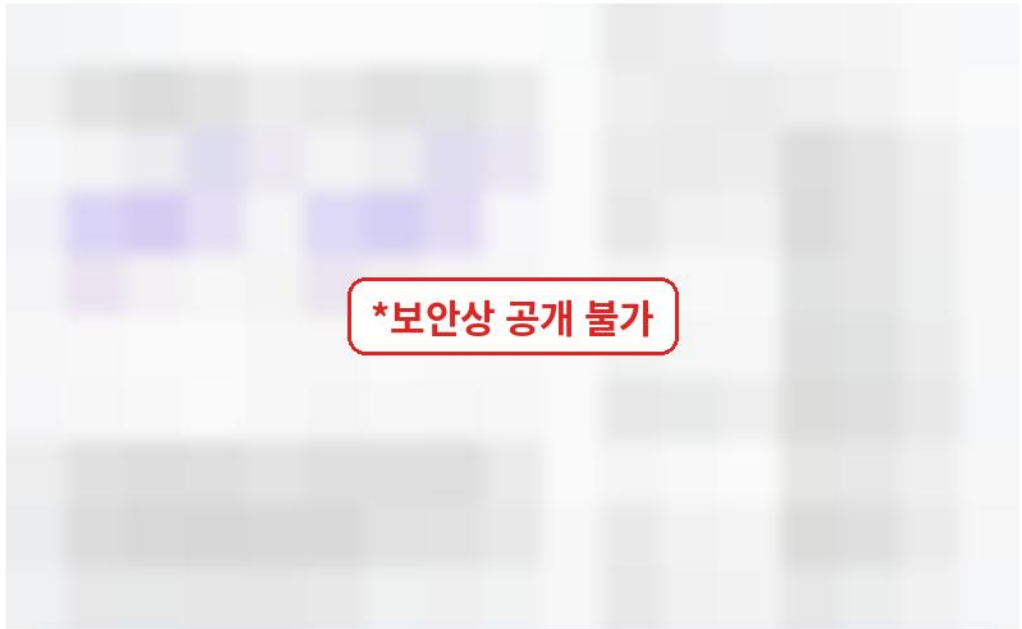


	LSTM	Transformer
분석 규모	43개의 분석 (총 10678줄)	16개의 분석 (남녀 통합 분석 적용)
초기 파일 구조	단일 R파일에 모든 코드 집중	주제별 주피터 노트북 분리
코드 품질 (초기)	주석-코드 심각한 불일치	주석-코드 일치
수행된 조치 사항	3개의 파일로 분리 및 주석 전면 수정/정제	수정 없이 즉시 코드 해석 진행

AI활용 인구추계 방법론 연구 보고서 검토 및 코드 정리 → 총 114페이지 정리본 완성

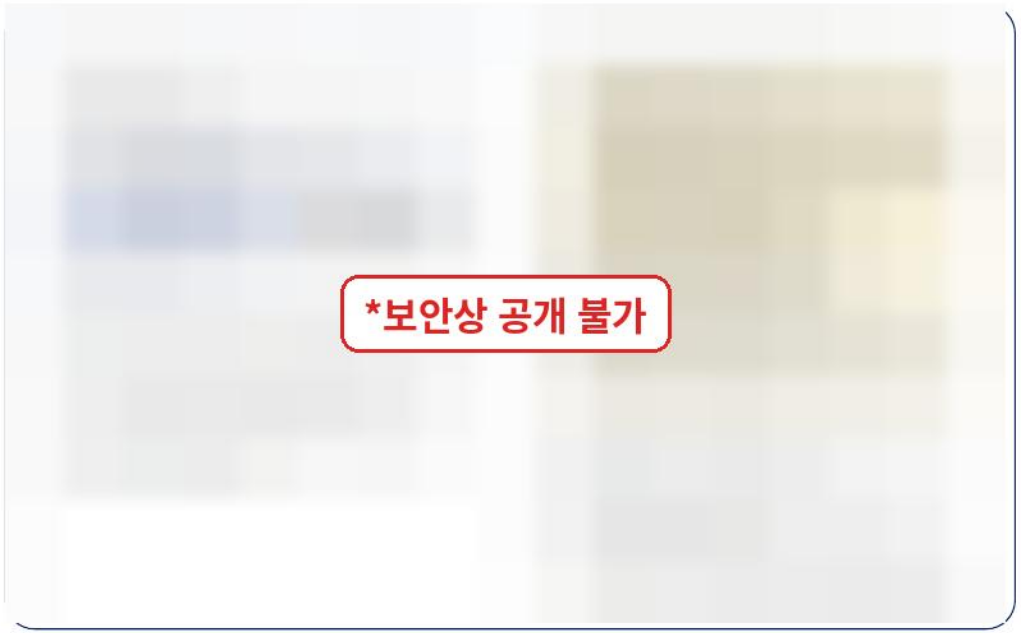
II. 조사 및 정리

2025년 업데이트 분석 보고서 및 공변량 보고서



- 2025년 업데이트 분석 보고서: 출산, 사망 (공변량 미반영) 분석을 진행하여 총 15쪽 보고서 완성 (공변량 반영은 당시 2025년 값이 없는 변수들이 있어서 없이 진행하였고, 추후에 2024년 값 이월하여 다시 분석)
- 공변량 보고서: 변수 산출공식과 출처자료를 정리한 2쪽의 보고서

2025년 외국인 유출입 관련 정책 및 보도자료 검토



고용노동부, 법무부, 교육부, 보건복지부 등 관련 부처의 공지사항과 보도자료를 검토하여 13쪽의 유출입관련 정책 보고서 완성

LSTM, Transformer

AI 방법론
핵심 예측 모델

LSTM (Long Short-Term Memory)

LSTM은 오래된 정보를 기억하고 새로운 정보를 적절하게 갱신하며 시계열 데이터의 장기의존성을 효과적으로 학습할 수 있도록 설계된 순환 신경망(RNN)의 발전된 형태

과거의 데이터가 현재에 미치는 영향을 파악하는 데 탁월하며, 내부의 3가지 게이트를 통해 정보를 통제

- 망각 게이트 (Forget Gate): 과거 정보 중 불필요한 노이즈를 제거

$ft = \sigma(Wf \cdot [ht-1, xt] + bf)$

- 입력 게이트 (Input Gate): 새로운 정보 중 장기 기억에 추가할 내용을 결정
- 출력 게이트 (Output Gate): 다음 시점으로 전달할 최종 요약 정보를 산출

이러한 구조 덕분에 기울기 소실 문제를 완화하여 장기적인 관성과 추세를 가진 데이터를 안정적으로 학습하고 예측

LSTM 코드 예시



Transformer

Transformer는 시계열 순차적 처리를 벗어나 어텐션 메커니즘을 통해 데이터 전체 시점을 한 번에 파악하여 모든 시점 간의 관계를 효율적으로 학습

시간적 거리에 얽매이지 않고 비선형적인 패턴이나 급격한 구조적 변화를 포착하는 데 강점

또한 전체 시계열에서 중요한 시점이나 패턴을 자동으로 찾아내고 그 관계를 기반으로 예측을 수행

Transformer 코드 예시



LSTM, Transformer

평가지표 (Metrics) 선정 전략

예측 모델의 성능을 평가할 때, 단일 지표에 의존하기보다 데이터의 스케일과 목적에 맞춰 두 지표를 상호 보완적으로 활용해야 함.

- **RMSE (평균 제곱근 오차):** 오차의 절대적 크기를 측정. 이상치에 강한 페널티를 부여하므로 급격한 변동을 잡아내는 것이 중요할 때 유용.
- **MAPE (평균 절대 비율 오차):** 오차를 백분율(%)로 나타내어 단위가 다른 데이터 간 비교에 적합. 단, 실제 값이 0에 근접할 경우 수학적으로 오차가 과대평가되는 왜곡 현상을 주의

LSTM 분석 과정

출산 - 교수님 분석 재연, 25년 업데이트 분석, 공변량 10개 조정 분석, 앵커0 조정 분석
사망 - 교수님 분석 재연 , 24년 업데이트 분석, 25년 업데이트 분석, 사망률 110세 조정 분석
국제이동 - 25년 업데이트 분석

Transformer 분석 과정

교수님 코드는 과거 추세를 보는 코드밖에 없어서 미래 예측 코드 새로 구성
출산, 사망, 국제이동은 LSTM과 동일한 시계열로 진행

인구 동태 변수별 최적화 전략

대상변수	최적 모델	공변량 반영 효과
출산 (1981-2025)	**LSTM** - 트랜스포머를 쓰면 모델이 과거의 특정 연도 데이터 구조를 통째로 외워버리는 문제(과적합)가 발생하기 쉬움 - 20대 후반에서 30대로 출산 연령이 서서히 이동해 온 45년간의 흐름을 LSTM이 상대적으로 더 안전하게 예측	**높음** (경제성장률, 혼인율 등 선행 지표 반영 시 성능 향상)
사망 (1970-2025)	**LSTM (**추세 유지에 압도적 유리) - 데이터 기간도 길고 연령별 사망률은 시간의 흐름에 따라 매우 규칙적인 곡선(나이가 들수록 높아지는 패턴과 의료 발전에 따른 서서히 낮아지는 추세)을 그림 - 트랜스포머의 복잡한 구조보다는, 과거부터 이어져 온 패턴과 연령별 흐름을 순차적으로 기억하는 LSTM이 과적합없이 안정적이고 높은 예측력을 보여줌	**낮음** (단일 변수 미반영 모델로도 충분한 예측력 확보)
국제이동 (2000-2025)	**Transformer** (비선형적 쇼크 대응) - 데이터가 26개년 뿐이라 딥러닝을 구현하기엔 너무 짧은 시간임 - LSTM이 시계열을 파악하기엔 기간이 너무 짧고, 국제이동 자체가 변동성이 엄청나게 크기 때문에 둘 다 예측력이 떨어질 위험이 큼 - 차라리 짧은 기간 안에서도 특정 경제 위기나 정책 변화 같은 외부 이벤트(공변량)와 데이터의 관계를 강하게 연결 짓는 트랜스포머가 그나마 나을 수 있음	**매우 높음** (외부 지표 없이는 방향성 예측 불가)

공변량

인구변동요인	외생변수	기초자료 시계열	보간방법	최종시계열
출생 (1981-2024) 연령별 출산율 추계	자녀에 대한 견해	2018-2024 (2년)	선형 보간	1981-2024
	유연근무 이용률	2015-2024	값 대체, 선형 보간	〃
	평균초혼연령	1990-2024	선형 보간	〃
	가족 내 성역할 인식	2008-2024 (2년)	회귀분석, 평균값 대체	〃
	학교급별 1인당 월평균 사교육비	2009-2024	회귀분석	〃
	보육시설 이용률	2008-2024 (2년)		〃
	저체중아 출생 비율	1993-2024	회귀분석	〃
	육아휴직 사용률	2015-2023	회귀분석	〃
	여성의 평균출산연령	1993-2024	선형 보간	〃
	청년층 정규직 근로자 비율	2003-2024		〃
사망 (1970-2023)	실업률	2000-2024	선형 보간	1970-2023
	연간적용인구 1인당 보험료	1990, 1995, 2000-2023	선형 보간, 지수 보간	〃
	연평균 1인당 진료비	1990,1995, 2000-2023	선형 보간, 지수 보간	〃
국제이동 (2000-2024)	외국인 근로자	2004-2022	선형 보간	2000-2025

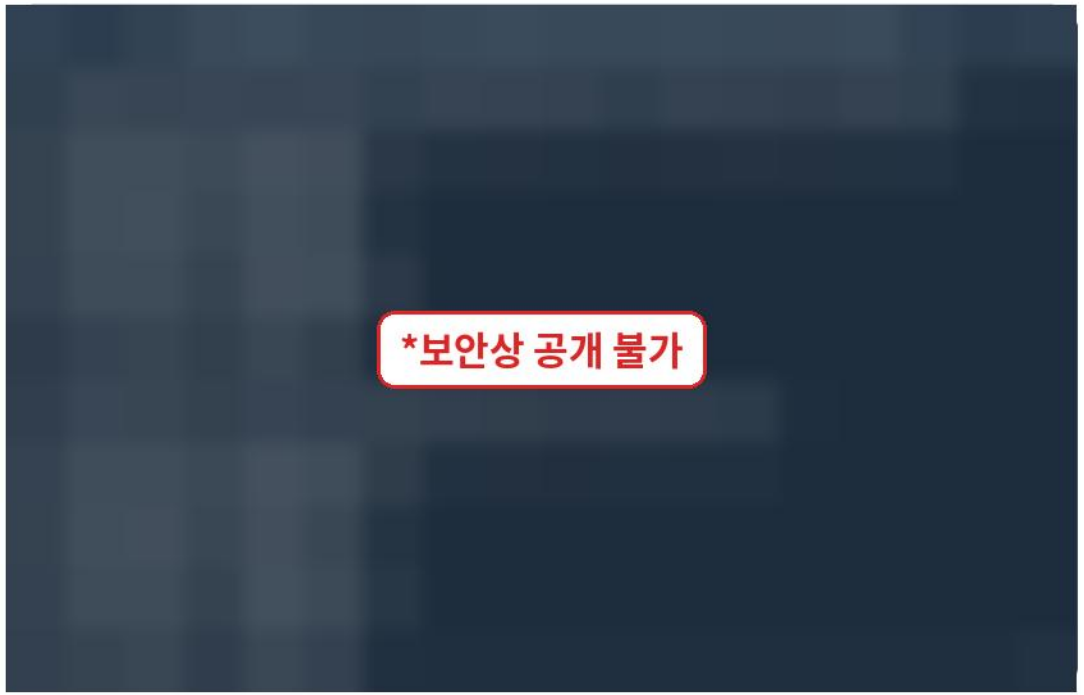
III. 출산 (LSTM)

5년예측: 공변량 미반영 vs 공변량 반영

*보안상 공개 불가

분석 기간
5년 예측: train: 1981-2020 test: 2021-2025 fore: 2026-2030
10년 예측: train: 1981-2015 test: 2016-2025 fore: 2026-2035

출산 분석 과정
교수님 24년 분석 재연 → 25년 업데이트 분석 →
공변량 10개 조정 분석 → 앵커0 조정 분석 →
총 22개 분석 결과 생성



합계출산율(TFR)과 세부 연령별 출산율(Cell) 모두 공변량 미반영 시의 예측력이 더 우수함

오차 지표인 RMSE, MAE, MAPE는 수치가 작을수록 예측 정확도가 높은데,
모든 지표에서 공변량 미반영 모델의 오차가 더 낮게 나타남
공변량 추가 시 오히려 예측 성능이 하락한 이유는 모델이 불필요한 정보
까지 복잡하게 학습하는 과적합이 발생했기 때문일 가능성이 큼
즉, 추가된 변수가 미래 추세 예측에 기여하기보다 본래의 시계열 패턴
파악을 방해하는 노이즈로 작용한 것임

III. 출산 (Transformer)

*보안상 공개 불가

과거 추세 분석 (5년)

*보안상 공개 불가

미래 예측 분석 (5년)

공변량 미반영 5년 예측 예시 (과거추세 VS 미래예측)

[트랜스포머 모델 예측 결과 비교]
비교 대상 - 연구용역 결과 vs. 2025년 업데이트 자료
예측력 평가 - 두 결과 모두 전반적인 예측력 저조
주요 한계점 - 과거 적합도 부족: 실제 데이터(파란색)와 예측치(빨간색) 간의 괴리 발생, **과대 예측:** 향후 출산율 전망치가 지나치게 높게 산출됨

과거 추세 분석의 경우 연구 용역과 2025년 업데이트 자료를 비교했을 때, 핵심 지표인 출산율 예측의 정확도가 전반적으로 하락하여 전체적인 모델 성능은 저하됨 (최종 검증 RMSE 0.0021에서 0.0047로 두 배 이상 증가)

결론: Test 데이터와 최종 검증 단계 모두에서 예측 오차가 증가하는 경향을 보임. 결과적으로 타겟인 출산율 5년 예측의 절대적인 오차(RMSE)가 전반적으로 상승하였으므로 해당 기법 적용 후 모델 성능 저하가 발생한 것으로 판단됨

IV. 사망 (LSTM)

1. **TEST 기간 재연**
   - 교수님 분석 재연 , 24년 업데이트 분석
2. **25년 업데이트 분석**
   - 교수님 분석과 같이 100세 이상 사망률은 무조건 1로 지정
   - 나머지 연령대는 0세부터 99세 주민등록연안인구수와 사망자수로 비율로 사망률 구함
3. **110세 데이터셋 조정**
   - 1970년부터 2025년까지의 여자남자전체 사망률(0-110세)로 분석 진행

rmse		
	여자	남자
공변량 미반영	0.01	0.01
공변량 반영	0.01	0.02

여자 사망률 5년 예측: 공변량 미반영 vs 반영



남자 사망률 5년 예측: 공변량 미반영 vs 반영



IV. 사망 (Transformer)

*보안상 공개 불가

*보안상 공개 불가

공변량 미반영의 경우, 핵심 지표인 사망률 5년 예측의 정확도가 연구용역에 비해 전반적으로 하락하여, 전체적인 모델 성능은 저하됨 (최종 검증 RMSE 0.0027에서 0.007로 증가)

결론: Test 데이터와 최종 검증 단계 모두에서 절대적인 예측 오차(RMSE)가 일제히 증가하는 경향을 보임. 결과적으로 타겟인 사망률 5년 예측의 모든 검증 지표에서 오차가 상승하여 해당 기법 적용 후 유의미한 모델 성능 저하가 발생한 것으로 판단

V. 국제이동 (LSTM)



남자 국제이동 공변량 미반영
Cell RMSE: 0.004557867
Cell MAE : 0.003262909
Cell MAPE: 43744122



남자 국제이동 공변량 반영
Cell RMSE: 0.004685734
Cell MAE : 0.003241606
Cell MAPE: 38987486

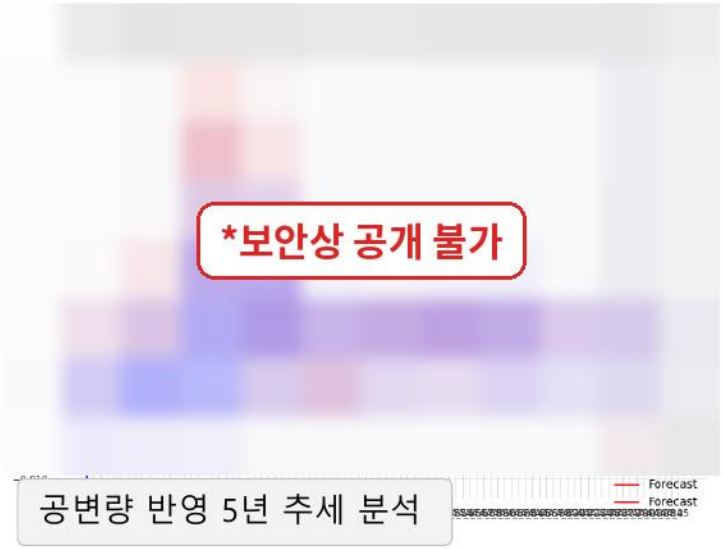
국제이동 데이터 특성상 특정 연령이나 구간에서 실제 이동 값이 0이거나 0에 극도로 가까운 미세한 값이 포함되어 있음

MAPE는 오차를 실제값으로 나누어 퍼센트를 구하는데, 분모(실제값)가 0이 되면 값이 무한대로 폭발해 버림
따라서 국제이동의 MAPE는 평가 지표에서 제외하는 것이 좋음

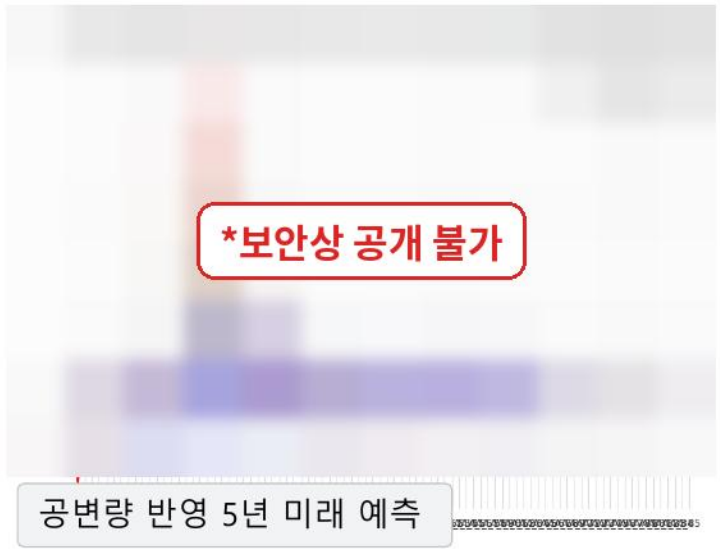
또한 공변량 추가의 득실은 없음
신뢰할 수 있는 지표인 RMSE(0.004대)와 MAE(0.003대)를 보면 오차 자체는 매우 작게 잘 잡히고 있으나 공변량을 반영하기 전과 후의 차이가 소수점 셋째~넷째 자리 수준으로 아주 미미함

즉, 모델에 추가한 공변량이 남성 국제이동의 예측력을 유의미하게 끌어올리지 못하고 있음

V. 국제이동 (Transformer)



공변량 반영 5년 추세 분석



공변량 반영 5년 미래 예측



위 그래프의 경우 파란색이 실제, 빨간색이 예측인데 **전반적인 추세는 잡았으나 세부적인 정밀도에서는 오차가 꽤 큼**

트랜스포머 모델이 전체적인 뼈대는 구성했으나, 딥러닝 특유의 평활화 현상 때문에 극단적인 뾰족한 값이나 미세한 변동을 둥글게 깎아서 예측하고 있음

시사점

01. 기존 방법론 진단

교수님의 분석 방법(딥러닝)을 그대로 유지하는 것이 타당한가에 대한 근본적 검토

방법론 및 데이터의 구조적 한계

재현성 결여 및 데이터 부족

컴퓨팅 환경 및 패키지에 따라 학습 효과가 상이하여 **기존 분석의 완벽한 재현이 불가**

또한 딥러닝 알고리즘이 유의미한 패턴을 학습하기에 절대적인 데이터 모수가 부족

공변량 불균형

출산 관련 공변량은 많은 반면, 사망(3개) 및 국제이동(1개)은 턱없이 부족

특히 사회적 변수의 영향을 가장 많이 받는 **국제이동의 공변량이 '외국인 근로자 수' 단 1개뿐**

초기 적합도 저조 및 누적 오차

기존 논문 수치 및 그래프에서도 **적합도가 낮음**

현 코드를 그대로 적용하여 시계열을 연장할 경우 예측률은 더욱 하락하므로 추가 조정이 필요

시사점

02. 가이드라인 정립

신뢰할 수 있는 예측 모델 구축을 위한 평가 기준 및 스코프 통일

예측 기간(Horizon)에 따른 리스크 분석

단기 예측 (5년)

- 공변량의 변동 및 불확실성이 **통제 가능한 범위 내**에 존재
- 과거 추세가 비교적 강력하게 유지되어 **비교적 높은 수준의 예측 정확도**를 확보
- 정책적 단기 대응을 위한 신뢰성 있는 지표 제공이 가능

장기 예측 (10년 이상)

- 과거 예측값을 기반으로 다시 미래를 도출하는 순환 구조로 인해 **작은 초기 오차가 기하급수적으로 누적**될 위험이 높음
- 장기적인 사회구조 변화(공변량 변동)를 딥러닝이 스스로 보정하지 못함
- **장기 예측 진행 시, 오차 누적을 방지하기 위한 조치가 필수적**

분석 스코프 및 평가 지표 표준화 과제

분석 스코프 및 목적 통일

모델 간 분석 대상이 파편화되어 있음
(LSTM: 남녀 전체 분석, Transformer: 통합 분석)
또한 미래 예측과 과거 추세 확인 등 **분석 목적이 혼재되어 있어 이에 대한 명확한 통일**이 선행되어야 함

파라미터 및 공변량 최적화

출산율 공변량 16개를 모두 투입하는 건지, 핵심 변수 10개로 할지 결정

예측률 변동에 따른 앵커조정 알고리즘 및 가이드라인을 설계 필요

평가 지표 단일화

모델 성능을 검증할 통일된 기준이 부재

Cell 단위의 개별 RMSE를 볼 것인지, 출산율 TFR RMSE를 기준으로 할지, 혹은 MAPE를 활용할 것인지 명확한 성과 평가 지표를 확립해야 함